哈爾濱工業大學

毕业设计（论文）

题　　目　基于深度学习的结肠镜息肉检测方法

专　　业　自动化

学　　号　150210226

学　　生　杨帆远航

指 导 教 师　高蕾

答 辩 日 期　2019 年 6 月 13 日

摘 要

结肠镜息肉检测是结直肠癌筛查的一种重要方式，可以在早期发现息肉并进行治疗，对于降低结直肠癌发病率和病死率具有重要意义。结肠镜是一项依赖操作者的检查，受人为因素的影响严重，对医疗行业操作者有较高技术要求。随着深度学习的进步和发展，深度学习已逐渐应用于各行各业中，将深度学习应用于结肠镜息肉检测中是深度学习在高精度医学图像检测的创新，极大地提高了结肠镜息肉检测的效率，使得深度学习在医学图像检测相关技术领域中得到巨大飞跃。

本文首先介绍了深度学习中常用的卷积神经网络的原理，将深度学习的目标检测方法运用到结肠镜息肉检测中。然后采用 MobileNetV2 算法，基于开源框架 TensorFlow 和 SSD 的开源框架，通过 Python 编程实现息肉检测的特征提取算法，构建结肠镜下计算机辅助息肉位置的检测模型。通过深度学习训练出识别率较高的结肠镜息肉检测模型，并通过交并比、准确率、损失函数等评价指标对模型进行评估。最后在修改卷积神经网络的基础上，对结肠镜息肉模型进行优化，模型对结肠镜息肉识别率达到 98%，交并比达到了 0.8 以上，训练出了符合评价指标的结肠息肉检测模型。

关键词：深度学习；结肠镜息肉检测；卷积神经网络；TensorFlow；检测模型训练

Abstract

Colonoscopy polyp detection is an important method of colorectal cancer screening, which can detect polyps early and treat them, and is of great significance to reduce the incidence and mortality of colorectal cancer.Colonoscopy is an examination dependent on the operator, which is seriously affected by human factors and has high technical requirements for the operator in the medical industry.With the progress and development of deep learning, deep learning has been gradually used in all walks of life, deep learning was applied to colonoscopy is deep learning in polyp detection in the innovation of the high precision medical image detection, greatly improve the efficiency of the colonoscopy polyp detection, makes deep learning in medical image detection technology in the field of giant leap.

Firstly, this paper introduces the principle of convolutional neural network commonly used in deep learning and applies the target detection method of deep learning to colonoscopy polyp detection.Then, MobileNetV2 algorithm, based on the open source framework TensorFlow and SSD, was used to implement the feature extraction algorithm of polyp detection through Python programming, and the detection model of computer-assisted polyp location under colonoscopy was constructed.The colonoscopy polyp detection model with high recognition rate was trained by deep learning, and the model was evaluated by intersection ratio, accuracy, loss function and other evaluation indexes.Finally, on the basis of modifying the convolutional neural network, the colonoscopy polyp model was optimized, and the colonoscopy polyp recognition rate of the model reached 98%, and the crossover ratio reached more than 0.8, so as to train a colon polyp detection model meeting the evaluation indexes.

Keywords: Deep learning;Colonoscopy polyp detection;Convolutional neural network;TensorFlow;Test model training

目 录

摘 要 ..... **I**

ABSTRACT ..... **II**

第 1 章 绪 论 **1**

1.1 课题背景及研究的目的和意义 1

1.1.1 课题背景 1

1.1.2 研究的目的和意义 2

1.2 结肠镜息肉检测的发展现状 3

1.2.1 国外现状及分析 3

1.2.2 国内现状及分析 3

1.3 深度学习的发展 3

1.4 研究内容 4

1.5 研究方法和技术路线 6

第 2 章 深度学习的环境配置 **6**

2.1 安装系统运行环境 6

2.2 安装 TENSORFLOW 运行环境 6

2.3 OBJECT-DETECTION API 安装及配置 8

2.4 本章小结 8

第 3 章 训练结肠息肉检测模型 **9**

3.1 创建数据集 9

3.2 对数据集进行标注 9

3.3 标注转换为 TFRECORD 格式 9

3.4 预训练模型配置 10

3.4.1 卷积神经网络结构 10

3.4.2 激活函数 13

3.4.3 池化的类型及特点 13

3.4.4 VGG16 网络结构 14

3.4.5 MobileNetV1 网络结构 15

3.5 本章小结 17

第 4 章 训练过程的评价指标 **17**

4.1 引言 17

4.2 损失函数评价 18

4.3 交并比评价 19

4.4 验证集评估 19

4.5 小结 21

第 5 章 优化结肠息肉模型 21
5.1 引言 21
5.2 结肠镜息肉检测模型优化前后对比 22
5.2.1 卷积神经网络的相同点 22
5.2.2 卷积神经网络的不同点 22
5.3 优化后模型效果 23
5.3.1 损失函数评价 24
5.3.2 交并比评价 24
5.3.3 验证集评估 25
5.4 本章小结 25
结 论 26
参考文献 26
致 谢 28

第 1 章 绪 论

1.1 课题背景及研究的目的和意义

1.1.1 课题背景

随着现代社会的工业化发展与科技水平的不断提高，人民的生活质量在不断提高，生活节奏也在加快，由此导致肠道疾病的发病率逐年上升。肠道病变和进一步恶化引发的癌变是人类健康的最大威胁之一，其严重影响了人们的正常生活。根据美国癌症协会发布的 2017 年全美癌症统计报告指出，全美肠道癌症的发病人数约为 30.5 万，其中女性约为 13.2 万，男性约为 17.3 万；由肠道病变引起的死亡人数达到了 15.3 万，其中女性约为 6.4 万，男性约为 8.9 万[1]。肠道病情早期检测和治疗是防止其继续恶化的关键所在，例如结肠癌，如果患有结肠癌的病人，能够在瘤变的早期阶段之前发现并采取了治疗手段，那么通常五年的存活率基本会超过 90%；如果任病情恶化，以致发展到中晚期，则患者的五年存活率低于 10%。因此，实现肠道组织病变的早期、精准检测，对降低病发率和死亡率具有十分重要的现实意义。

结肠是腹腔内的管状器官，长约 1.5m，从右侧腹部延伸至左侧，形状像一个“门”字。小肠在右下腹通过回盲袢与结肠相连。结肠结构如图 1 所示，分升结肠、横结肠、降结肠和乙状结肠 4 部，大部分固定于腹后壁。

结肠癌是全球常见的肠道系统恶性肿瘤之一。大多数结肠癌源于腺瘤性息肉，结肠镜检查作为结直肠癌筛查的一种重要方式，可以早期发现息肉并进行活组织检查切除，对于降低结直肠癌发病率和病死率具有重要意义。结肠镜是一项依赖操作者的检查，受视觉敏感性、疲劳、注意力不集中等人为因素的影响，可能出现息肉漏检的情况。如何提高白光内镜下结肠息肉检出率是一个有待解决的问题。

目前，针对息肉识别的计算机决策支持系统(decision support systems，DSS)主要有息肉检测(polyp detection)和息肉分割(polyp segmentation)两类[2]。息肉检测主要关注是否有息肉的问题，通过框出息肉位置以提醒检查者。息肉分割除了检测息肉外，还可勾勒出息肉的轮廓，给出较准确的病灶边界。相比之下，息肉分割技术提供的信息更具体，对算法的要求更高；息肉检测技术则相对简便，对于临床上常规内镜检查而言，帮助操作者判断息肉的有无即主要任务，更加精细的诊治过程可交由息肉分类(polyp classification)技术或病理活组织检查来解决。

在机器学习领域中，深度学习是其中一个比较前沿的研究方向，从目前最近

这几年来看，深度学习在众多领域应用中得到了飞跃性的发展，比如语音识别、计算机视觉等[3]。深度学习是通过建立网络模型，模拟人类的大脑中的神经网络体系结构，然后在不同阶段分不同层次进行对图像、声音、文本等数据特征进行提取，最后给出一些数据信息的合理描述。

深度学习是机器学习的一个新领域，是学习样本数据所属的自然属性及规律，通过学习的过程中能够得到事物的相应的有用信息，比如文字、图形图像以及声音信号等数据信息，从而能够帮助人们能够更好的理解这些数据信息[4]。它最后的目标就是能够帮助人们提高对事物的分析能力、识别能力以及对图像信息的处理能力。深度学习能够使机器模仿人的视听以及思考等活动，帮助人类解决了较多的复杂的识别问题，从而使得人工智能能够在相关技术领域及行业中得到巨大飞跃。

1.1.2 研究的目的和意义

社会在发展，人们生活质量也日渐改善，然而，人们的工作压力同样也越来越大，身体健康也受到了极大的影响，肠道疾病发病率越来越高，结肠的正常与否对人体健康状况影响甚大，异常轻微时，消化不良，营养缺失，严重时，出现无法进食，人体日渐消瘦，若未及早治疗，死亡率非常之高。

图 1 结肠结构图

结肠息肉是一种良性肿瘤，如图 1 所示，其结肠粘膜凸起异常生长，结肠息

肉还会致使肠套叠，从而引发肠阻塞发生腹痛。因此，对结肠镜图像息肉自动检测，并且能够快速、准确地筛选结肠息肉图像是当前急需解决的关键问题，在临床医学上具有重要的现实意义和临床价值。

1.2 结肠镜息肉检测的发展现状

1.2.1 国外现状及分析

国外已报道过息肉检测和分类技术在 CT 结肠成像(仿真结肠镜)、胶囊内镜、结肠镜、窄带成像技术(Narrow Band Imaging，NBI)方面的研究。美国 Ravesteijn 团队正在研究 CT 结肠成像使用计算机辅助检测后的误差回归问题[5]。在小肠病变自动检测研究中，往往根据小肠病变的程度不同，其小肠图像表现出的图像特征也对应不同，病变程度较轻时，其病灶特征与正常小肠图像区别不是很大，甚至肉眼也难以发现，因此对于相似度较高图像就很容易引起误判，分为各类的最大似然概率值一般都会比较接近，似是而非，也是临床上最不愿看到的结果。2017 年，美国 Bernal J 团队实现了将病变程度等级细分，也就是将一种病变继续分成多类，同时详细地对结肠镜下息肉检测方法进行了比较验证，对临床诊断具有重要意义。

1.2.2 国内现状及分析

截至目前，国内仅有息肉检测技术在 CT 结肠成像方面的报道，而鲜有结肠镜的相关研究，只有少数研究团队对计算机辅助结肠镜检测结肠肿瘤做出了准确性的临床研究，对结肠肿瘤通过纹理进行计算机辅助病理分类[6]。在临床研究方面，国内正在进行计算机辅助检测结肠肿瘤准确性的临床试验。

1.3 深度学习的发展

1957 年，Rosenblatt 提出感知器，但无法解决非线性数据的分类，后又学者提出剁成神经网络能够解决非线性问题，但却没有提出多层神经网络的有效训练方法。1986 年 Rumelhar 和 Hinton 提出了 BP 算法，解决了两层乃至多层的神经网络训练问题，解决了非线性分类问题。

2006 年 Hinton 首次提出“深度信念网络”，传统的训练方式采样随机初始化的方式来初始化权值参数，但该网络利用预训练（pre-training）的过程，可以方便神经网络中的权值找到一个接近最优解的初始值，再用“微调”技术（fine-tuning）技术对整个网络进行优化训练。这两个技术有效的减小了网络的训练时间，并缓

解了神经网络 BP 算法导致的梯度消失的问题。给神经网络赋予了新名称——深度学习。

深度学习真正受人瞩目是 2012 年的 ImageNet 比赛，Hinton 的学生利用多层卷积神经网络成功的对包含一千类别的一百万张图片进行了训练，分类错误率只有 15%，比第二名低了近 11 个百分点，此后深度学习呈爆发式的发展。

深度学习的兴起离不开大数据和高性能的计算平台的推动，分别被称为 “引擎”和“燃料”。深度学习的成功需要依靠大量的训练数据来进行学习，大数据是深度学习的基础；另一方面，对大量数据的学习和训练，效率问题很难解决，就需要硬件设施的加速发展。

1.4 研究内容

深度学习，实际上的本质是构建包含很多个隐藏层的机器学习架构模型，通过训练大量的训练样本集数据，然后从训练中学习到事物中具有代表性特征信息。深度学习和传统机器学习有许多区别，深度学习模型结构层次较多，隐藏层节点层数一般都在五层以上，有时候甚至可以达到十层以上。深度学习明确强调了特征学习在深度模型中的重要性，通过每一层的特征提取，使样本数据在初始空间特征转换到另一个新的特征空间来表示新的初始数据，从而使分类、预测等一些问题变的更加容易实现[7]。而传统的机器学习是需要人工设计与提取特征的，因此较深度学习而言，深度学习模型学习到的数据特征，在大数据的内在丰富信息中更具有代表性。

卷积神经网络(Convolutional Neural Networks, CNN)是深度学习(deep learning)的代表算法之一，和一般常用的神经网络是有所不同的。在卷积神经网络中，由特征提取器和分类器组成，而特征提取器是由一个卷积层和降采样层构成的。在卷积层里，它由一个神经元和部分邻层神经元相连接，卷积神经网络前段部分是一个特征提取的过程，后段部分即为分类器，在全连接层时，可以看作是传统机器学习分类器中的特征信息输入部分。综合起来说，卷积神经网络通过卷积来模拟特征区分，并且通过卷积的权值共享来降低网络参数的数量级，最后通过传统神经网络完成分类等任务。

通常一个卷积神经网络是由输入层（Input）、卷积层（Convolution）、池化层（Pooling）、全连接层（Fully Connected）组成。在输入层输入原始数据，卷积层中进行的是前面所述的卷积过程，用它来进行提取特征。全连接层就是将识别到的所有特征全部连接起来，并输出到分类器（如 Softmax）。池化层都是用于对卷积层输出特征进行压缩，以加快运算速度，也可以对于一些特征的检测过程变

得更稳健。

在池化过程中采用较多的一种方法叫最大池化（Max Pooling）。池化的过程类似于卷积过程，且池化过程中没有需要进行学习的参数。把一个大小为 4×4 的矩阵分成四个等块，经过最大池化，取每一个区域中的最大值，输出一个大小为 2×2 的矩阵。这个池化过程中相当于使用了一个大小滤波器，且池化步长为 2。

池化过程一般在卷积过程之后，而卷积过程是个提取特征的过程。把上面的 4×4 的输入看作某些特征的集合，则数字大就意味可能提取到了某些特定特征，Max 池化的功能提取出这些特定特征，将它们保留下来。也还有一种平均池化（Average Pooling）的方法，就是从从以上取某个区域的最大值改为求这个区域的平均值。

采用卷积神经网络能够建立出更好的模型，获得更为出色的表现，在于其拥有的一些突出的优点。对于大量的输入数据，卷积过程有效地减少了参数数量，而这主要归功于以下两点：

（1）参数共享(Parameter Sharing)：在卷积过程中，不管输入有多大，一个特征探测器也就前面所说的滤波器就能对整个输入的特征进行探测。

（2）局部感知(Local Perception)：在每一层中，输入和输出之间的连接是稀疏的，每个输出值只取决于输入的一小部分值。

池化过程则在卷积后很好地聚合了特征，通过降维而减少了运算量。

卷积神经网络中的 VGG(Visual Geometry Group) 模型是 2014 年 The ImageNet Large Scale Visual Recognition Challenge (ILSVRC) 竞赛的第二名，第一名是 GoogleNet。但是 VGG 模型在多个迁移学习任务中的表现要优于 GoogleNet。而且，从图像中提取卷积神经网络特征，VGG 模型是首选算法，以 VGG 模型为基础改进的 MobileNetV1 在准确率和运行速度上都有较好的表现。

目前息肉检测的特征提取方法主要有手工设定(hand-crafted)、端到端学习(end-to-end learning)、混合方法(hybrid approach)三类[8]。手工设定特征主要利用低水平图像处理方法得到息肉的候选边界，然后用这些信息定义息肉独特的边界特征。例如，分析探测到边界的曲率；寻找与息肉相关的椭圆形形状；研究组合以上两种策略中曲率的分析和形状的拟合[9]。在端到端学习方法中，纹理和颜色信息曾被用作描述因子，例如使用局部二值模式(Binary Patterns, BP)特征。后来，出现了组合手工设定和端到端学习的混合方法。例如：Tajbakhsh 等[10]组合了边缘检测和特征提取，提升了检测的准确性；Sevo 等组合了边缘密度和卷积网络。以上方法通常使用低水平的简单特征来检测息肉，或只把用卷积网络得到的特征用来做图片的整体分类，没有具体检测息肉的位置。

1.5 研究方法和技术路线

本研究将深度学习的目标检测方法运用到结肠镜息肉检测中。采用 Mobilenet 算法，基于开源框架 Tensorflow 和 SSD 的开源框架实现，通过 Python 实现息肉检测的特征提取算法，构建结肠镜下计算机辅助息肉位置的检测方法。

在此基础上按训练集大小和结肠息肉图片复杂度设置多个试验组，在不同训练集下，计算该模型检测结肠镜息肉的准确度、交并比及损失函数等目标检测评价指标，具体过程如图 2 所示。

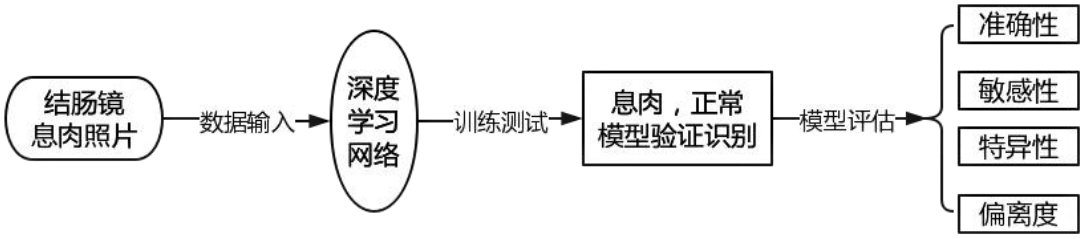

图 2 技术路线

第 2 章 深度学习的环境配置

2.1 安装系统运行环境

深度学习（deep learning）是机器学习的一大分支，它试图在机器上建立模仿人脑机制进行分析学习的神经网络，赋予机器解释图像、声音、文本等数据的能力。

由传统卷积网络衍生为新型卷积神经网络成为深度学习发展趋势[11]，近现代网络模型经过改良演变，模型结构变化重组，简化网络复杂度，优化网络性能，在目标识别率上大幅度提升，并最终应用于结肠镜息肉目标检测领域。

考虑到系统稳定性因素，采用 Linux 的 Ubuntu 18.04 系统运行之后的程序，在虚拟机上下载并安装系统安装包，Ubuntu 系统安装完成。

2.2 安装 TensorFlow 运行环境

TensorFlow 是 Google 基于 DistBelief 进行研发的第二代人工智能学习系统，是一个使用数据流图进行数值计算的开源软件库。其命名来源于本身的运行原理，

Tensor(张量)意味着 N 维数组，Flow（流）意味着基于数据流图的计算，TensorFlow 便意为张量从流图的一端流动到另一端计算过程。TensorFlow 中包含了一款强大的线性代数编译器 XLA，这可以帮助 TensorFlow 代码在嵌入式处理器、CPU（Central Processing Unit）、GPU（Graphics Processing Unit）、TPU（Tensor Processing Unit）和其他硬件平台上尽可能快速地运行。

TensorFlow 最为简洁的安装方式是用 Anaconda 的集成虚拟环境，可以免去手工安装 CUDA 驱动的麻烦[12]。Anaconda 指的是一个开源的 Python 发行版本，其包含了 conda、Python 等 180 多个科学包及其依赖项。使用 Anaconda 配置环境变量，在 Anaconda 中新建一个 tf2 虚拟环境作为深度学习训练环境，使在终端中运行 python 命令时，执行的是 Anaconda 里的 python 程序及环境。

其中 Tensor 是张量的意思，在 tensorflow 中可以被简单理解为多维数组，表明了它的数据结构。 而 Flow 中文翻译是“流”，直观地表达了张良之间通过计算相互转换的过程。

Tensorflow 是一个通过计算图的形式来表述计算的系统。每一个计算都是计算图上的一个节点，而节点之间的边描述了计算之间的依赖关系。如果一个运算的输入依赖于另外一个运算的输出，那么这两个运算有依赖关系。

在 TensorFlow 程序中，所有的数据都通过张量的形式来表示。从功能的角度上看，张量可以被简单理解为多维数组。其中零阶张量表示标量（scalar），也就是一个数（或字符串）；第一阶张量为向量（vector），也就是一个一维数组；第 n 阶张量可以理解为一个 n 维数组。张量中并没有真正保存数字，它保存的是如何得到这些数字的计算过程，只是对 TensorFlow 中运算结果的引用，其中保存了三个属性：name , shape , type。三个属性的定义及特点如下：

（1）第一个属性，name。通过“node:src_output”的形式给出。其中，node 是节点的名称，src_output 表示当前张量来自节点的第几个输出。比如”add_2:0”就说明 result 这个张量是计算节点“add_2”输出的第一个结果（编号从 0 开始）。

（2）第二个属性，shape。描述了一个张量的维度信息。

（3）第三个属性，type。描述了张量 result 的类型。参与运算的张量类型需要保一致。

卷积神经网络中的计算顺序是通过 TensorFlow 中的会话（session）来执行定义好的运算。会话拥有并管理 TensorFlow 程序运行时的所有资源，当所有计算完成之后需要关闭会话来帮助系统回收资源，否则就可能出现资源泄漏的问题。有两种会话使用模式。第一种模式是明确调用会话生成的函数和关闭会话函数。第

二种则是通过 Python 的上下文管理器来使用会话。所以计算放在“with”内部，上下文管理器退出的时候会自动释放所有资源。

2.3 Object-Detection API 安装及配置

TensorFlow 中的对象检测 API 是一个建立在 TensorFlow 之上的开源框架，可以更快的构建和训练结肠息肉检测模型[13]。Object Detection API 是谷歌开放的一个内部使用的物体识别系统。2016 年 10 月，该系统在 COCO 数据集识别挑战中名列第一。它支持当前最佳的实物检测模型，能够在单个图像中定位和识别多个对象。该系统不仅用于谷歌于自身的产品和服务，还被推广至整个研究社区。

Tensorflow Object Detection API 依赖很多组件包，例如 Protobuf 2.6，Python-tk，Pillow 1.0，lxml，tf Slim，Jupyter notebook，Matplotlib，cocoapi 等。在 Anaconda 的搜索框里搜索组件，安装并检验已全部安装。组件包安装完成后，在 research 文件夹下添加环境变量 PYTHONPATH，运行环境变量测试程序，运行成功确保安装成功。

在确保安装完成后，打开 Anaconda 组件 Jupyter Notebook 运行 Google 官方提供的目标检测程序，运行结果如图 3 所示，可顺利进行狗的目标检测。至此，安装及配置工作基本完成。

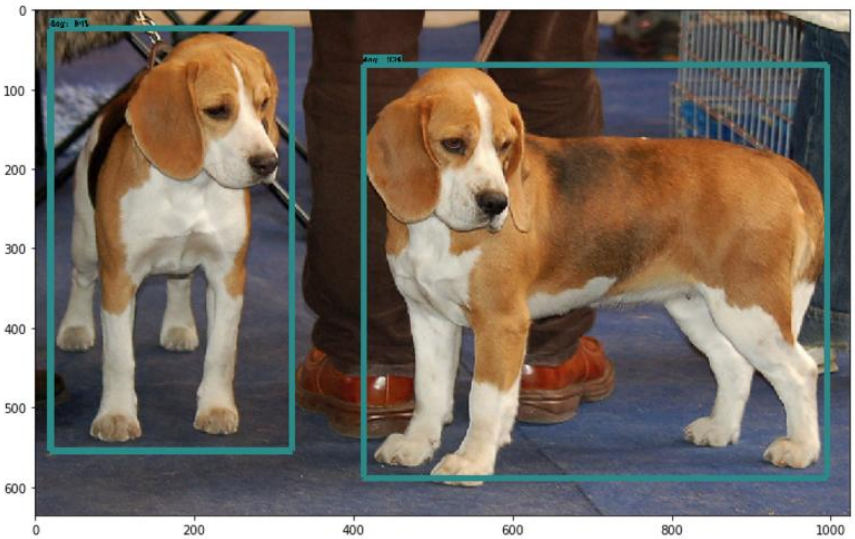

图 3 狗的目标检测

2.4 本章小结

本章在深度学习的基础上，搭建出了可以进行训练结肠镜息肉检测模型的软硬件环境。结肠镜息肉检测模型是在传统卷积神经网络模型之上与 TensorFlow 中

的目标检测模块结合的深度学习网络模型，在目标识别率上有大幅度的提升，为最终应用于医学图像目标检测打下了坚实基础。

第 3 章 训练结肠息肉检测模型

3.1 创建数据集

深度学习需要数据作为原料，首先需要建立起一个可供训练的数据集，同时利用符合 TensorFlow 的数据格式来保存这些数据及其标签。将实验室已分类的结肠息肉照片进行筛选，去除有抖动的不清晰图片，将筛选后的 583 张图片作为数据集。

结肠息肉照片预处理则是对图像进行去噪等操作，对于医学图像数据，有常见的求平均值与归一化数据等方式。候选区域是可以获取需要准确定位图片或者视频当中目标的位置和目标尺寸大小，候选区域的生成传统的方法是采用选择性搜索算法，从一张图像采用分割方法与合并规则相结合来生成多个小图，基于各个小图组合成候选区域。再对图像当中候选区域进行特征提取，对提取出的特征向量进行筛选。采用特征分类器对各个特征进行分类，该特征分类将确定候选区域是否具有目标主体。确定出目标位置，用既定边框准确定位出目标位置。而卷积神经网络作为提取特征主要主体结构，通过分类器进行目标种类判别。

3.2 对数据集进行标注

对训练集中的图片标注，就是用一个文件来描述图中物体的位置框坐标（xmin，ymin，xmax，ymax），用来定位物体的位置[14]。采用常用的标注软件 LabelImg 进行图片标注，在 LabelImg 主程序中，导入结肠息肉数据集，对每一张图片用矩形框进行标注，如图 4 所示，共标注 583 张数据集图片。

3.3 标注转换为 TFRecord 格式

利用 TensorFlow 提供的将 pascal voc 格式转换为 TFRecord 格式的程序脚本，同时对数据集地址进行修改[15]。定义好类别 ID 与类别名称的关系，用 pbtxt 格式文件保存，类别 ID 为 1，类别名称为结肠息肉 polyp of colon。新建两个文本文件 train.txt 和 val.txt，在 train.txt 中录入训练集图片名称，在 val.txt 中录入验证集图片名称。

运行格式转换脚本，生成 TFRecord 文件，程序输出 if not xml，说明执行成

功，由此得到训练集文件和验证集文件，其中训练集图片 500 张，验证集图片 83 张。

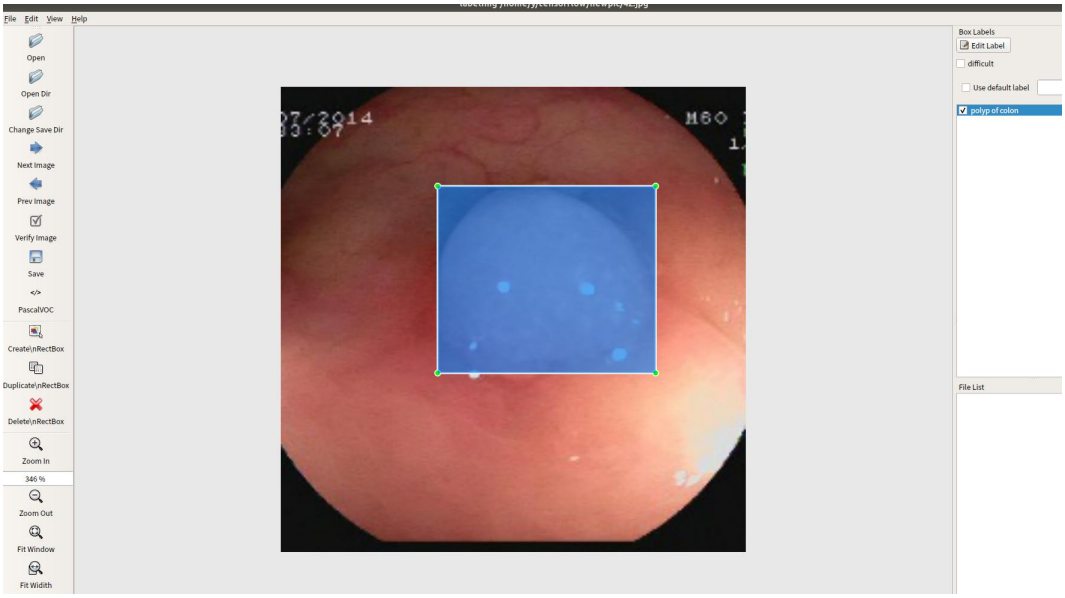

图 4 标注训练集图片

3.4 预训练模型配置

预训练采用 SSD_MobileNetV1 卷积神经网络算法对数据集进行深度学习训练，SSD（The Single Shot Detector）是基于前馈卷积网络，针对那些方框里的目标类别实例，产生一个固定大小的边界框的集合和分数，紧接着一个非最大抑制步骤去产生最后的检测。

3.4.1 卷积神经网络结构

早期的网络是一个标准的结构，用于对高质量图片进行分类，舍弃了最后的分类层，叫做基网络。然后对网络增加放大结构去产生多比例特征图检测，在基网络最后增加了卷积特征层[16]。这些层按照大小减少的次序连接，能够进行多尺度预测。同时会产生卷积检测预测器，每个添加的特征层或者现存的来自基网络的特征层，在使用一个卷积滤波器集合的情况下，可以产生一个固定集合的检测预测。

卷积神经网络的输入层可以处理多维数据，常见地，一维卷积神经网络的输入层接收一维或二维数组，其中一维数组通常为时间或频谱采样；二维数组可能包含多个通道；二维卷积神经网络的输入层接收二维或三维数组；三维卷积神经网络的输入层接收四维数组[17]。由于卷积神经网络在计算机视觉领域有广泛应用，

因此许多研究在介绍其结构时预先假设了三维输入数据，即平面上的二维像素点和 RGB 通道。

与其它神经网络算法类似，由于使用梯度下降进行学习，卷积神经网络的输入特征需要进行标准化处理。具体地，在将学习数据输入卷积神经网络前，需在通道或时间/频率维对输入数据进行归一化处理，若输入数据为像素，也可将分布于 0 到 255 的原始像素值归一化至 0 到 1 的区间内。同时输入特征的标准化有利于提升算法的运行效率和学习表现[18]。

卷积神经网络的隐含层包含卷积层、池化层和全连接层 3 类常见构筑，在一些更为现代的算法中可能有 Inception 模块、残差块（residual block）等复杂构筑。在常见构筑中，卷积层和池化层为卷积神经网络特有。卷积层中的卷积核包含权重系数，而池化层不包含权重系数，因此，池化层可能不被认为是独立的层。以 VGG 卷积神经网络为例，3 类常见构筑在隐含层中的顺序通常为：输入-卷积层-池化层-卷积层-池化层-全连接层-输出。

卷积层的功能是对输入数据进行特征提取，其内部包含多个卷积核，组成卷积核的每个元素都对应一个权重系数和一个偏差量（bias vector），类似于一个前馈神经网络的神经元（neuron）。卷积层内每个神经元都与前一层中位置接近的区域的多个神经元相连，区域的大小取决于卷积核的大小，在深度学习领域内被称为“感受野（receptive field）”，其含义可类比视觉皮层细胞的感受野[19]。卷积核在工作时，会有规律地扫过输入特征，在感受野内对输入特征做矩阵元素乘法求和并叠加偏差量。

以二维卷积核作为例子，一维或三维卷积核的工作方式与之类似。理论上卷积核也可以先翻转 180 度，再求解交叉相关，其结果等价于满足交换律的线性卷积（linear convolution），但这样做在增加求解步骤的同时并不能为求解参数取得便利，因此线性卷积核使用交叉相关代替了卷积。

特殊地，当卷积核是大小为 1，步长为 1 且不包含填充的单位卷积核时，卷积层内的交叉相关计算等价于矩阵乘法，并由此在卷积层间构建了全连接网络。

由单位卷积核组成的卷积层也被称为网中网（Network-In-Network, NIN）或多层感知器卷积层（multilayer perceptron convolution layer, mlpconv）[20]。单位卷积核可以在保持特征图尺寸的同时减少图的通道数从而降低卷积层的计算量。完全由单位卷积核构建的卷积神经网络是一个包含参数共享的多层感知器（Muti-Layer Perceptron, MLP）。

在线性卷积的基础上，一些卷积神经网络使用了更为复杂的卷积，包括平铺卷积（tiled convolution）、反卷积（deconvolution）和扩张卷积（dilated

convolution）[21]。平铺卷积的卷积核只扫过特征图的一部份，剩余部分由同层的其它卷积核处理，因此卷积层间的参数仅被部分共享，有利于神经网络捕捉输入图像的旋转不变（shift-invariant）特征 。反卷积或转置卷积（transposed convolution）将单个的输入激励与多个输出激励相连接，对输入图像进行放大。由反卷积和向上池化层（up-pooling layer）构成的卷积神经网络在图像语义分割（semantic segmentation）领域有重要应用，也被用于构建卷积自编码器（Convolutional AutoEncoder, CAE）。扩张卷积在线性卷积的基础上引入扩张率以提高卷积核的感受野，从而获得特征图的更多信息，在面向序列数据使用时有利于捕捉学习目标的长距离依赖（long-range dependency）。使用扩张卷积的卷积神经网络主要被用于自然语言处理（Natrual Language Processing, NLP）领域，例如机器翻译、语音识别等。

在卷积层参数方面，卷积核中 RGB 图像的按 0 填充。卷积层参数包括卷积核大小、步长和填充，三者共同决定了卷积层输出特征图的尺寸，是卷积神经网络的超参数[22]。其中卷积核大小可以指定为小于输入图像尺寸的任意值，卷积核越大，可提取的输入特征越复杂。

卷积步长定义了卷积核相邻两次扫过特征图时位置的距离，卷积步长为 1 时，卷积核会逐个扫过特征图的元素，步长为 n 时会在下一次扫描跳过 n-1 个像素。

由卷积核的交叉相关计算可知，随着卷积层的堆叠，特征图的尺寸会逐步减小，例如 16×16 的输入图像在经过单位步长、无填充的 5×5 的卷积核后，会输出 12×12 的特征图。为此，填充是在特征图通过卷积核之前人为增大其尺寸以抵消计算中尺寸收缩影响的方法。常见的填充方法为按 0 填充和重复边界值填充（replication padding）。填充依据其层数和目的可分为四类：

（1）有效填充（valid padding）：即完全不使用填充，卷积核只允许访问特征图中包含完整感受野的位置。输出的所有像素都是输入中相同数量像素的函数。使用有效填充的卷积被称为“窄卷积（narrow convolution）”，窄卷积输出的特征图尺寸较小。

（2）相同填充/半填充（same/half padding）：只进行足够的填充来保持输出和输入的特征图尺寸相同。相同填充下特征图的尺寸不会缩减但输入像素中靠近边界的部分相比于中间部分对于特征图的影响更小，即存在边界像素的欠表达。使用相同填充的卷积被称为“等长卷积（equal-width convolution）”。

（3）全填充（full padding）：进行足够多的填充使得每个像素在每个方向上被访问的次数相同。步长为 1 时，全填充输出的特征图尺寸较大，一般大于输入值。使用全填充的卷积被称为“宽卷积（wide convolution）”

（4）任意填充（arbitrary padding）：介于有效填充和全填充之间，人为设定的填充，较少使用。

带入卷积神经网络中，若 16×16 的输入图像在经过单位步长的 5×5 的卷积核之前先进行相同填充，则会在水平和垂直方向填充两层，即两侧各增加 2 个像素变为 20×20 大小的图像，通过卷积核后，输出的特征图尺寸为 16×16，保持了原本的尺寸。

3.4.2 激活函数

卷积层中包含激活函数以协助表达复杂特征，类似于其它深度学习算法，卷积神经网络通常使用线性整流单元（Rectified Linear Unit, ReLU），其它类似 ReLU 激活函数的变体包括有斜率的 ReLU（Leaky ReLU, LReLU）、参数化的 ReLU（Parametric ReLU, PReLU）、随机化的 ReLU（Randomized ReLU, RReLU）、指数线性单元（Exponential Linear Unit, ELU）等。在 ReLU 出现以前，Sigmoid 函数和双曲正切函数（hyperbolic tangent）是常用的激活函数。

激活函数操作通常在卷积核之后，一些使用预激活（preactivation）技术的算法将激活函数置于卷积核之前。在一些早期的卷积神经网络研究，例如 VGG16 网络中，激活函数在池化层之后。

在卷积层进行特征提取后，输出的特征图会被传递至池化层进行特征选择和信息过滤。池化层包含预设定的池化函数，其功能是将特征图中单个点的结果替换为其相邻区域的特征图统计量。池化层选取池化区域与卷积核扫描特征图步骤相同，由池化大小、步长和填充控制。

3.4.3 池化的类型及特点

在卷积神经网络中，池化的方法有很多。其中，Lp 池化（Lp pooling）是一类受视觉皮层内阶层结构启发而建立的池化模型，其一般表示形式较为复杂。其中关于步长、像素的含义与卷积层相同，步长是预指定参数。当步长为 1 时，Lp 池化在池化区域内取均值，被称为均值池化（average pooling）；当步长趋于无穷时，Lp 池化在区域内取极大值，被称为极大池化（max pooling）。均值池化和极大池化是最常见的池化方法，二者以损失特征图尺寸为代价保留图像的背景和纹理信息。此外步长为 2 时的 L2 池化在一些工作中也有使用。

另外的池化方法是混合池化（mixed pooling）和随机池化（stochastic pooling），它们是 Lp 池化概念的延伸。随机池化会在其池化区域内按特定的概率分布随机选取一值，以确保部分非极大的激励信号能够进入下一个构筑。混合池化可以表示

为均值池化和极大池化的线性组合。与此同时，混合池化和随机池化有利于防止卷积神经网络的过度拟合，比均值和极大池化有更好的表现。

除此之外，谱池化是基于 FFT 的池化方法，可以和 FFT 卷积一起被用于构建基于 FFT 的卷积神经网络。在给定特征图尺寸和池化层输出尺寸时，谱池化对特征图的每个通道分别进行 DFT 变换，并从频谱中心截取 n×n 大小的序列进行 DFT 逆变换得到池化结果。谱池化有滤波功能，可以最大限度地保存低频变化信息，并能有效控制特征图的大小。此外，基于成熟的 FFT 算法，谱池化能够以很小的计算量完成。

3.4.4 VGG16 网络结构

VGG16 网络模型的原始版本是 GoogleNet 使用的版本，VGG16 网络模型中有多个卷积层和池化层进行堆叠所得的特殊隐含层构筑。具体而言，一个 VGG16 模块会同时包含多个不同类型的卷积和池化操作，并使用相同填充使上述操作得到相同尺寸的特征图，随后在数组中将这些特征图的通道进行叠加并通过激活函数。由于上述做法在一个构筑中引入了多个卷积计算，其计算量会显著增大，因此为简化计算量，VGG16 模块通常设计了瓶颈层，首先使用单位卷积核，这样的结构减少特征图的通道数，再进行其它卷积操作。VGG16 模块最早被应用于 GoogleNet 并取得了显著的成功，也启发了之后的算法中的深度可分卷积（depthwise separable convolution）思想。

VGG16 卷积神经网络中的全连接层等价于传统前馈神经网络中的隐含层。全连接层通常搭建在卷积神经网络隐含层的最后部分，并只向其它全连接层传递信号。特征图在全连接层中会失去 3 维结构，被展开为向量并通过激活函数传递至下一层。

在一些卷积神经网络中，全连接层的功能可部分由全局均值池化（global average pooling）取代，全局均值池化会将特征图每个通道的所有值取平均，即若有 7×7×256 的特征图，全局均值池化将返回一个 256 的向量，其中每个元素都是 7×7，步长为 7，无填充的均值池化。

VGG16 卷积神经网络中输出层的上游通常是全连接层，因此其结构和工作原理与传统前馈神经网络中的输出层相同。对于图像分类问题，输出层使用逻辑函数或归一化指数函数（softmax function）输出分类标签。在物体识别（object detection）问题中，输出层可设计为输出物体的中心坐标、大小和分类。在图像语义分割中，输出层直接输出每个像素的分类结果 。

3.4.5 MobileNetV1 网络结构

Google 在 2017 年提出适用于移动端的神经网络模型 MobileNetV1[23]，主要使用了深度可分离卷积将卷积核进行分解计算来减少计算量，引入了两个超参数宽度乘数和分辨率乘数来减少参数量和计算量。深度可分离卷积将一个标准的卷积核分成深度卷积核和点卷积核[24]，如图 5 所示，可以清晰看出标准卷积核和深度可分离卷积核的结构与区别。

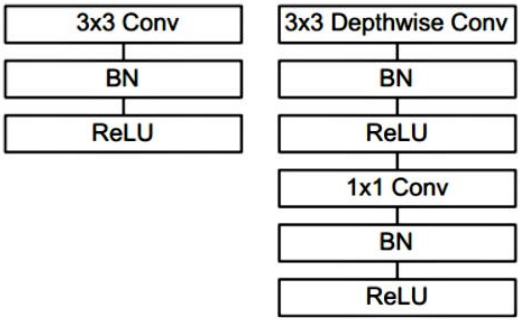

图 5 标准卷积核和深度可分离卷积核对比

Type / Stride	Filter Shape	Input Size
Conv / s2	$3 \times 3 \times 3 \times 32$	$224 \times 224 \times 3$
Conv dw / s1	$3 \times 3 \times 32$ dw	$112 \times 112 \times 32$
Conv / s1	$1 \times 1 \times 32 \times 64$	$112 \times 112 \times 32$
Conv dw / s2	$3 \times 3 \times 64$ dw	$112 \times 112 \times 64$
Conv / s1	$1 \times 1 \times 64 \times 128$	$56 \times 56 \times 64$
Conv dw / s1	$3 \times 3 \times 128$ dw	$56 \times 56 \times 128$
Conv / s1	$1 \times 1 \times 128 \times 128$	$56 \times 56 \times 128$
Conv dw / s2	$3 \times 3 \times 128$ dw	$56 \times 56 \times 128$
Conv / s1	$1 \times 1 \times 128 \times 256$	$28 \times 28 \times 128$
Conv dw / s1	$3 \times 3 \times 256$ dw	$28 \times 28 \times 256$
Conv / s1	$1 \times 1 \times 256 \times 256$	$28 \times 28 \times 256$
Conv dw / s2	$3 \times 3 \times 256$ dw	$28 \times 28 \times 256$
Conv / s1	$1 \times 1 \times 256 \times 512$	$14 \times 14 \times 256$
$5\times$ Conv dw / s1	$3 \times 3 \times 512$ dw	$14 \times 14 \times 512$
Conv / s1	$1 \times 1 \times 512 \times 512$	$14 \times 14 \times 512$
Conv dw / s2	$3 \times 3 \times 512$ dw	$14 \times 14 \times 512$
Conv / s1	$1 \times 1 \times 512 \times 1024$	$7 \times 7 \times 512$
Conv dw / s2	$3 \times 3 \times 1024$ dw	$7 \times 7 \times 1024$
Conv / s1	$1 \times 1 \times 1024 \times 1024$	$7 \times 7 \times 1024$
Avg Pool / s1	Pool 7×7	$7 \times 7 \times 1024$
FC / s1	1024×1000	$1 \times 1 \times 1024$
Softmax / s1	Classifier	$1 \times 1 \times 1000$

图 6　MobileNetV1 结构图

MobileNetV1 的卷积神经网络结构如图 6 所示，MobileNetV1 共有 28 层（深度卷积和点卷积单独算一层），可以看出 conv13 是骨干网络的最后一层，仿照

VGG-SSD 的结构[25]，MobileNetV1 的 conv13 后面添加了 8 个卷积层，一共抽取 6 层用作检测。

MobileNetV1 的卷积神经网络模型结构输入层由大小为 300×300 图像组成，该网络结构基于 VGG16 网络模型框架结合多卷积层网络，SSD 网络总体由两部分组成，前部分主要采用卷积网络提取图像特征，以原有 VGGl6 网络结构作为共享网络，包括输入层，卷积层，下采样层。

MobileNetV1 的卷积神经网络模型的后部分将卷积层代替原始全连接层，卷积层逐层递减，以多尺度滑动窗口特征提取层级结构为主体。其中，SSD 模型结构后部分由 5 种不同大小卷积层组成，输出的特征图(Feature Map)叫分别用两个不同的 3×3 的卷积核进行卷积，彩色图像便采用 3 通道卷积核。在多尺度特征图中增加了一个特征图单元盒(Default Box)，每个特征图单元盒需要预测 c 个类别，有 k 个单元盒，特征图大小为 m×n，采用 3×3 卷积核对该层特征进行卷积，输出分为两个部分，类别概率和特征图单元盒回归后坐标。将实际中选择的特征单元盒(Prior Box)要与完整目标盒 (Ground Box)进行匹配，该特征单元盒应用在多个不同卷积层特征图，网络模型最终得到 8732 个输出。

由于 SSD 模型前部分采用 VGG16 结构，神经元单元结构以及卷积函数类似卷积神经网络，SSD 模型存在训练损失函数，包括定位损失函数与回归损失函数等评价指标。

综合准确率和快速性考虑，使用 SSD_MobileNetV1 卷积神经网络作为预训练神经网络算法，在 Github 上下载模型程序包，并解压到 object detection 目录下，对 ssd_mobilenet_v1_coco.config 文件修改参数。参数包括图片批次大小 batch_size、学习率 initial_learning_rate、迭代次数 num_steps 等。

批次大小是每一次训练神经网络送入模型的样本数，在卷积神经网络中，大批次通常可使网络更快收敛，但由于内存资源的限制，批次过大可能会导致内存不够用或程序内核崩溃。

学习率是指在优化算法中更新网络权重的幅度大小。学习率可以是恒定的、逐渐降低的，基于动量的或者是自适应的。不同的优化算法决定不同的学习率。当学习率过大则可能导致模型不收敛，损失函数不断上下震荡；学习率过小则导致模型收敛速度偏慢，需要更长的时间训练。

迭代次数是指整个训练集输入到神经网络进行训练的次数，当测试错误率和训练错误率相差较小时，可认为当前迭代次数合适；当测试错误率先变小后变大时则说明迭代次数过大了，需要减小迭代次数，否则容易出现过拟合。

经过大量测试，确定最优的初始训练参数，初始设置 batch_size=4，

initial_learning_rate=0.004，num_steps=10000。结肠息肉模型训练运行过程如图 7 所示。

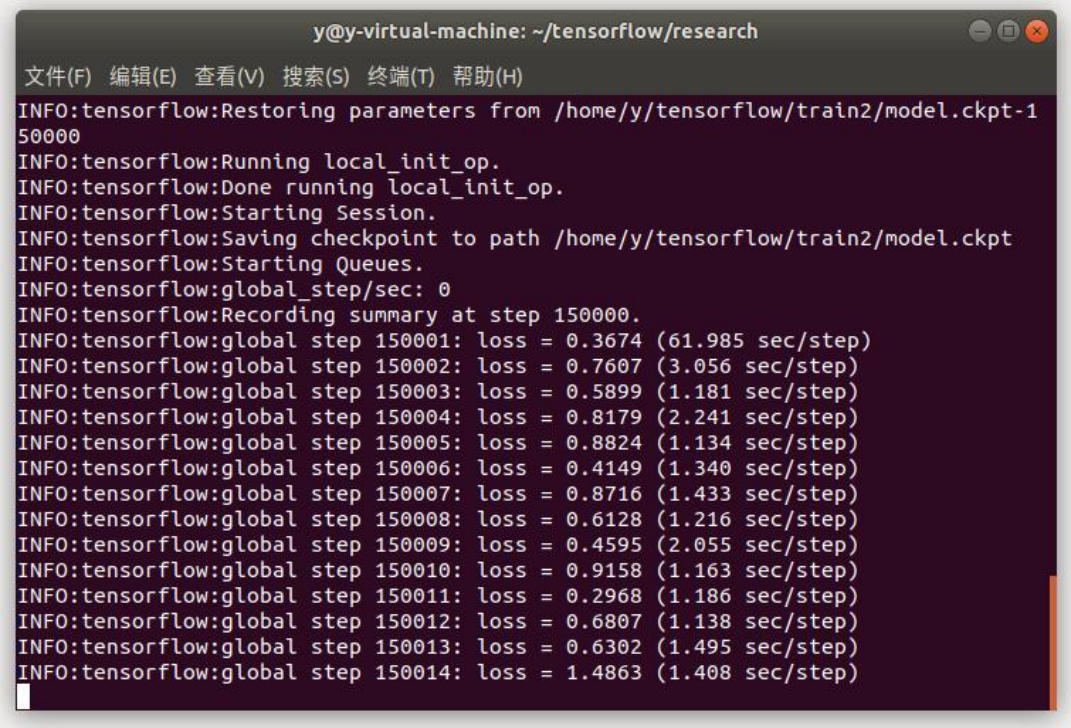

图 7 基于 MobileNetV1 结肠息肉模型训练过程

3.5 本章小结

训练出符合预期要求的结肠镜息肉模型是本次毕业设计中的核心，同时也是本章内容的重点。对结肠镜息肉图片进行预处理是训练前的准备工作，特征点明显的数据集图片将直接影响到训练效果及深度学习程度。训练过程中采用基于SSD的MobileNetV1的卷积神经网络对数据集图片进行学习，训练学习过程中较为顺利，可通过一系列评价指标进行评估。

第 4 章 训练过程的评价指标

4.1 引言

为了更方便的对 Tensorflow 程序的调试与运行过程优化，Google 发布了一套叫做 TensorBoard 的可视化工具。可以用 TensorBoard 来展现 TensorFlow 模型训练过程图像，绘制训练过程生成的定量指标图及附加数据[26]。TensorBoard 通过读取

训练模型的事件文件来运行。训练模型的事件文件包括了结肠息肉模型训练所涉及到的主要数据。TensorBoard 有如图 8 所示的评价指标，包括学习率、损失函数、交并比等。

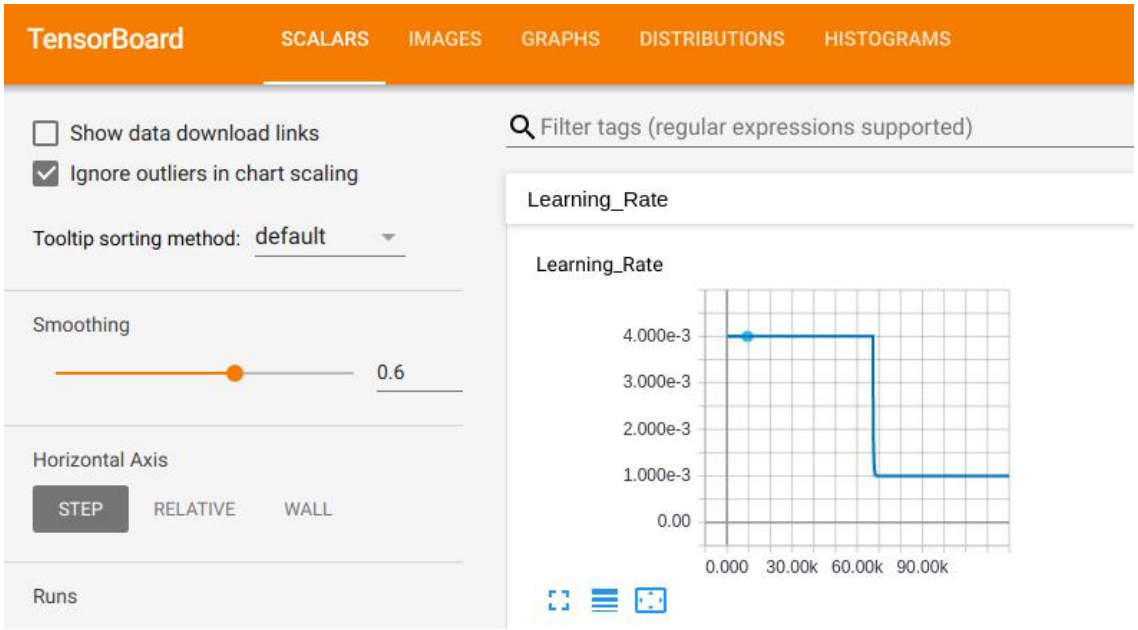

图 8 TensorBoard 界面

4.2 损失函数评价

损失函数（loss function）是用来估量模型的预测值 f(x)与真实值 Y 的不一致程度，它是一个非负实值函数,通常使用 L(Y, f(x))来表示，损失函数越小，模型的鲁棒性就越好[27]。

训练过程中的损失函数逐渐降低，图 9 是训练过程中的损失函数变化过程。从 10000 步开始，损失函数下降到 0.2 左右，继续训练，在 30000 步左右开始，损失函数完全下降到 0.1 以下。

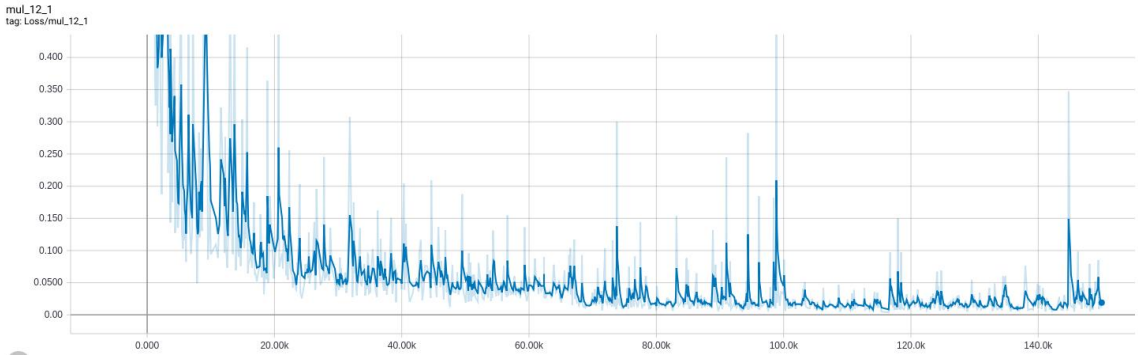

图 9 损失函数

4.3 交并比评价

交并比是目标检测算法性能计算的一个非常重要的函数[15]，如图 10 所示，交并比计算的是“预测的边框”和“真实的边框”的交集和并集的比值。

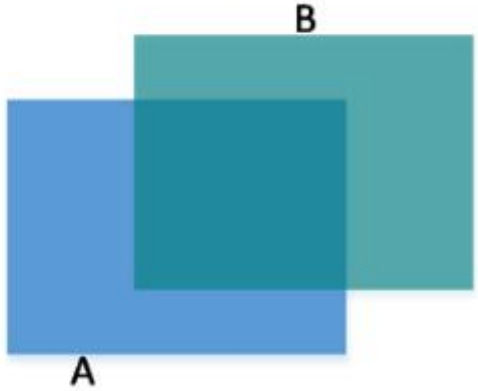

图 10 交并比评价指标

训练过程中的交并比变化如图 11 所示，训练到 35000 步后，交并比大于 0.6，说明训练整体方向正确。训练到 60000 步左右时，交并比大于 0.75，准确率进一步得到提升。

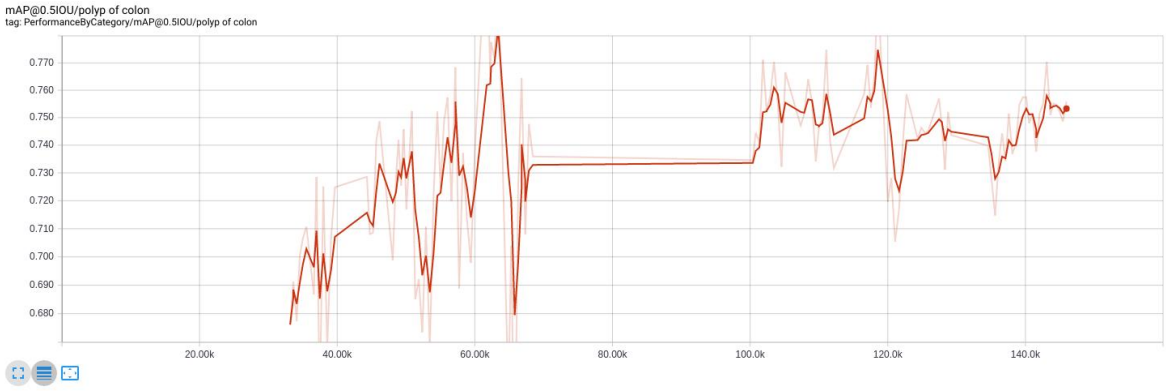

图 11 交并比训练结果

4.4 验证集评估

在模型训练过程中，一般需要将样本分成训练集，验证集和测试集。其中训练集用来估计模型，验证集用来确定网络结构或者控制模型复杂程度的参数，而测试集则检验最终选择最优的模型的性能如何。

可以用 TensorBoard 来展现 TensorFlow 模型训练过程图像，在训练目录下新建一个 eval 目录,用于保存 eval 的文件。运行 eval 程序可实时观测训练效果的变化，图 12 展示了 eval 运行的实时结肠息肉检测效果。

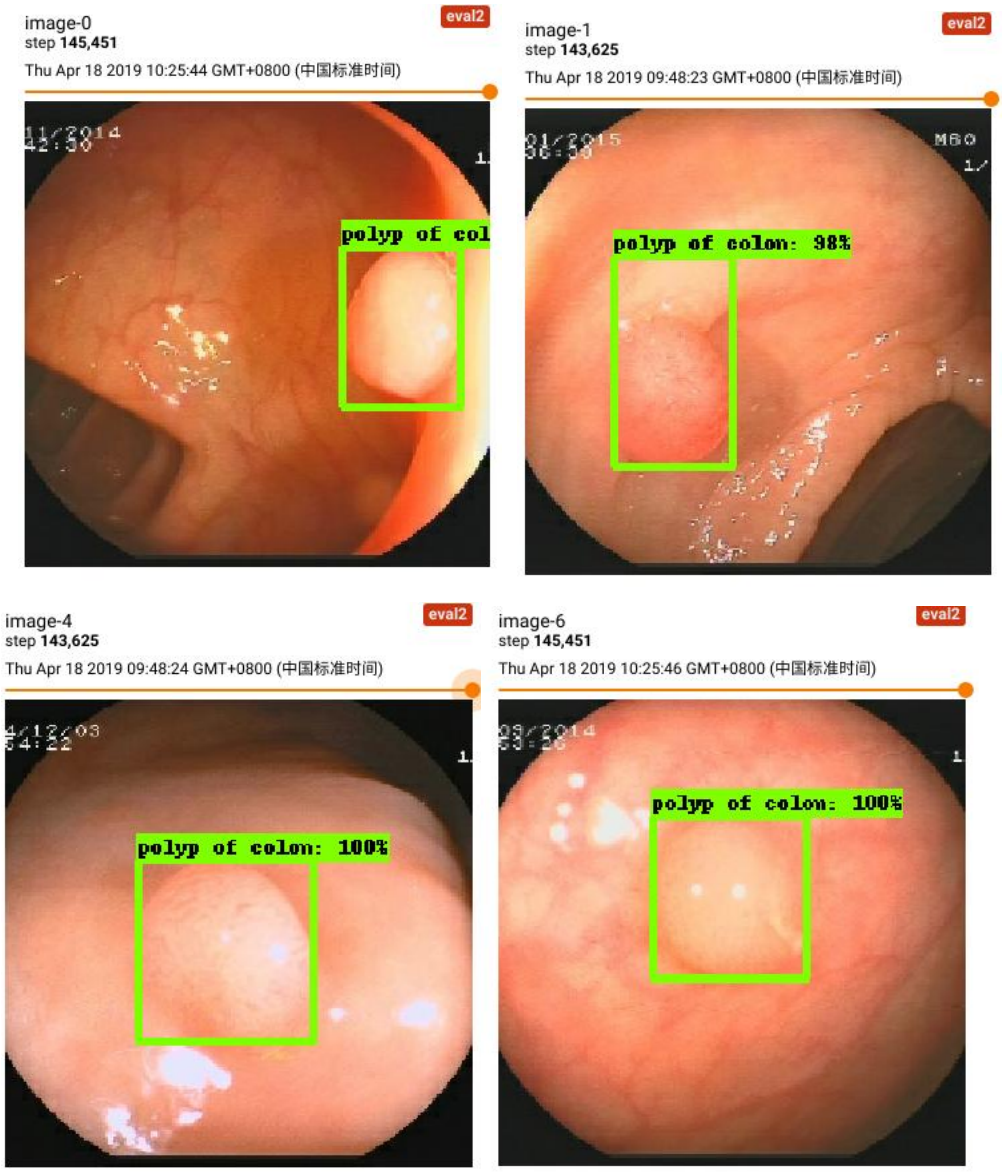

图 12 eval 查看训练效果

验证集是模型训练过程中单独留出的样本集，它可以用于调整模型的超参数和用于对模型的能力进行初步评估。在神经网络中，我们用验证数据集去寻找最优的网络深度，或者决定反向传播算法的停止点或者在卷积神经网络中选择隐藏层神经元的数量[28]。

在普通的机器学习中常用的交叉验证就是把训练数据集本身再细分成不同的验证数据集去训练模型。交叉验证法的作用就是尝试利用不同的训练集和验证集

划分来对模型做多组不同的训练/验证，来应对单独测试结果过于片面以及训练数据不足的问题。

验证集的作用是确定网络结构或者控制模型复杂程度的参数。对学习出来的模型，调整分类器的参数，如在神经网络中选择隐藏单元数。验证集还用来确定网络结构或者控制模型复杂程度的参数。模型拟合的训练数据集可以进一步划分成训练集和验证集。验证集是训练数据集的子集，用于对模型能力进行初步评估。

4.5 小结

通过大量结肠镜息肉数据集训练出结肠息肉模型，并通过损失函数、交并比、平均精确率均值等具有代表性的评价指标对结肠息肉模型进行了评估。训练出的结肠镜息肉模型在评价指标的评估下可以看出，MobileNetV1 的训练速度较为优秀，但是在交并比、准确率等方面虽然已达到预期结肠镜息肉检测效果，但仍然有进一步提升的空间。

第 5 章 优化结肠息肉模型

5.1 引言

结肠镜息肉模型的优化采用 MobileNetV2 的卷积神经网络模型进行，MobileNetV2 和 MobileNetV1 相比，主要改进点在于引入了残差结构，先升维再降维，增强梯度的传播，显著减少推理期间所需的内存占用（Inverted Residuals）。同时去掉了卷积层 Narrow layer（low dimension or depth）后的激活函数 ReLU，保留了特征多样性，增强网络的表达能力（Linear Bottlenecks）。

MobileNetV2 卷积神经网络模型结构如图 13 所示，MobileNetV2 卷积神经网络为全卷积的卷积神经网络，使得模型可以适应不同尺寸的图像；使用 ReLU6（最高输出为 6）激活函数，使得模型在低精度计算下具有更强的鲁棒性。

MobileNetV2 building block 在需要下采样的时候，可在设置步长大小时采用步长为 2 的卷积；小网络使用小的扩张系数（expansion factor），大网络使用大一点的扩张系数（expansion factor），本次毕业设计选取的扩张系数为 5，达到了较好的训练效果。

Input	Operator	t	c	n	s
$224^2 \times 3$	conv2d	-	32	1	2
$112^2 \times 32$	bottleneck	1	16	1	1
$112^2 \times 16$	bottleneck	6	24	2	2
$56^2 \times 24$	bottleneck	6	32	3	2
$28^2 \times 32$	bottleneck	6	64	4	2
$28^2 \times 64$	bottleneck	6	96	3	1
$14^2 \times 96$	bottleneck	6	160	3	2
$7^2 \times 160$	bottleneck	6	320	1	1
$7^2 \times 320$	conv2d 1x1	-	1280	1	1
$7^2 \times 1280$	avgpool 7x7	-	-	1	-
$1 \times 1 \times k$	conv2d 1x1	-	k	-	

图 13 MobileNetV2 卷积神经网络模型结构

5.2 结肠镜息肉检测模型优化前后对比

5.2.1 卷积神经网络的相同点

MobileNetV2 和 MobileNetV1 卷积神经网络都采用 Depth-wise (DW) 卷积搭配 Point-wise (PW) 卷积的方式来提特征。这两个操作合起来也被称为 Depth-wise Separable Convolution，之前在其他神经网络中被广泛使用。这么做的好处是理论上可以成倍的减少卷积层的时间复杂度和空间复杂度。

5.2.2 卷积神经网络的不同点

MobileNetV2 卷积神经网络模型在 DW 卷积之前新加了一个 PW 卷积。这么做的原因，是因为 DW 卷积由于本身的计算特性决定它自己没有改变通道数的能力，上一层给它多少通道，它就只能输出多少通道。所以如果上一层给的通道数本身很少的话，DW 卷积也只能在低维空间提特征，因此效果不够好。现在 MobileNetV2 卷积神经网络模型为了改善这个问题，给每个 DW 卷积之前都配备了一个 PW 卷积，专门用来升维，定义升维系数，这样不管输入通道数 是多少，经过第一个 PW 卷积升维之后，DW 卷积都是在相对的更高维进行着工作的。其中，MobileNetV2 和 MobileNetV1 卷积神经网络在时间和空间复杂度等方面的对比如图 14 所示，可以看出，MobileNetV2 卷积神经网络模型有着更多的卷积层数以提高性能。

模型	卷积层数	时间复杂度 MFLOPS	空间复杂度 MParams	CPU Inference
MobileNet V1	28 (13 DW)	575	4.2	120 ms
MobileNet V2	54 (17 DW)	300	3.4	80 ms

图 14 MobileNetV2 和 MobileNetV1 网络结构对比

MobileNetV2 卷积神经网络模型去掉了第二个 PW 卷积的激活函数。这个激活函数称其为 Linear Bottleneck。这么做的原因，是因为激活函数在高维空间能够有效的增加非线性，而在低维空间时则会破坏特征，不如线性效果好[29]。由于第二个 PW 卷积的主要功能就是降维，因此按照上面的理论，降维之后就不宜再使用 ReLU6 激活函数了。

5.3 优化后模型效果

训练后的 MobileNetV2 卷积神经网络模型训练过程如图 15 所示，由于卷积层的增加，优化后的结肠镜息肉检测模型在训练过程中训练速度慢了很多。

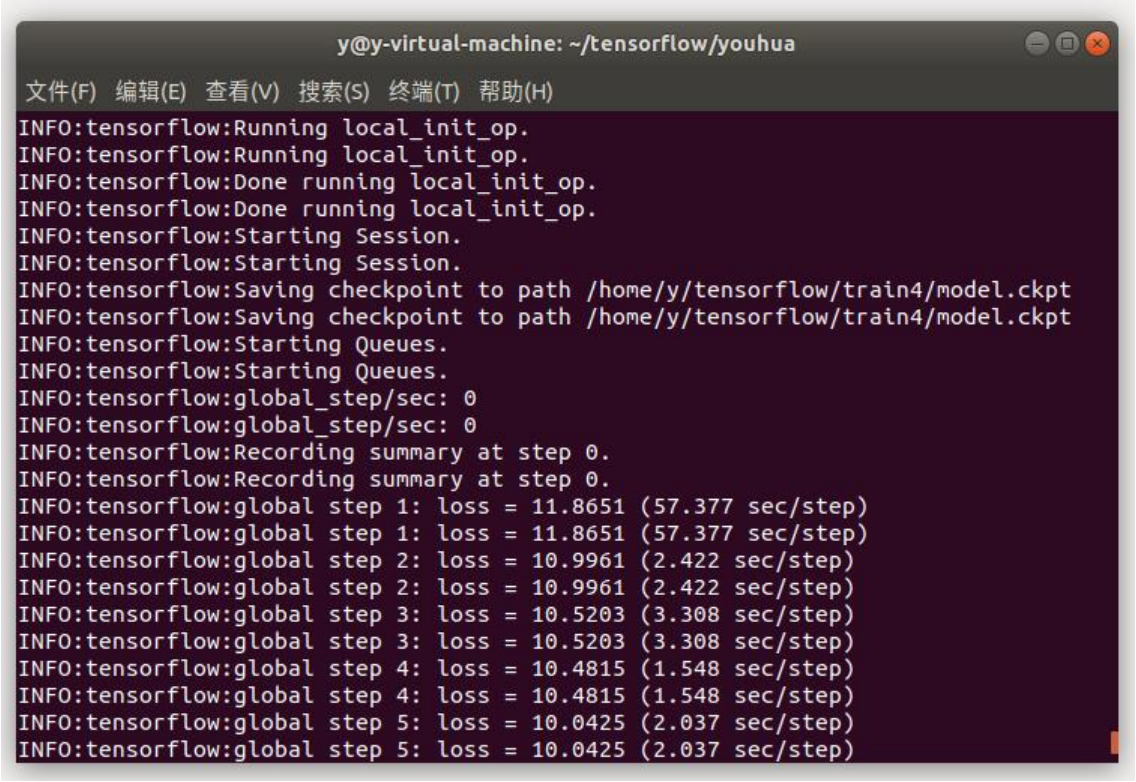

图 15 基于 MobileNetV2 结肠息肉模型训练过程

5.3.1 损失函数评价

优化后的 MobileNetV2 卷积神经网络训练模型在训练过程中的损失函数逐渐降低，图 16 是训练过程中的损失函数变化过程。从 1000 步开始，损失函数下降到 0.1 左右，继续训练，在 6000 步左右开始，损失函数完全下降到 0.05 以下，相比于 MobileNetV1 卷积神经网络模型的损失函数，MobileNetV2 卷积神经网络在更少的训练步数下达到了更低的损失函数，效果十分明显。

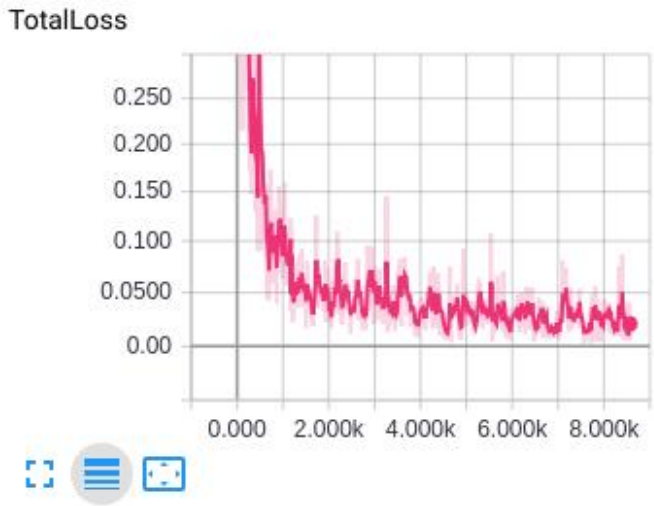

图 16 优化后的损失函数

5.3.2 交并比评价

MobileNetV2 卷积神经网络模型训练过程中的交并比变化如图 17 所示，训练到 200 步后，交并比大于 0.8，说明训练整体方向正确。训练到 5000 步左右时，交并比大于 0.95，准确率进一步得到提升，优化后的交并比相较之前提升 20%。

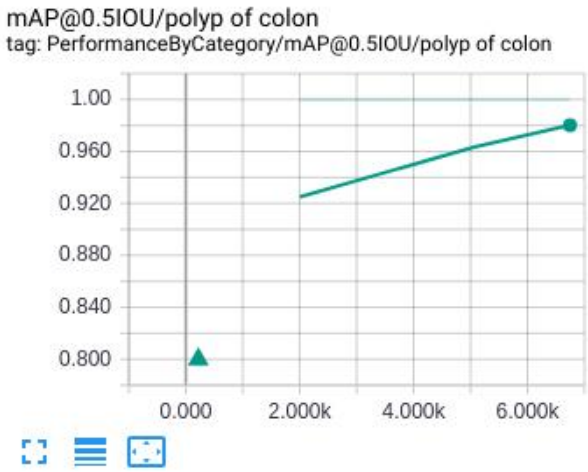

图 17 优化后的交并比

5.3.3 验证集评估

运行 eval 程序可实时观测训练效果的变化，图 18 展示了 eval 运行的优化后的结肠息肉模型检测效果，和 MobileNetV1 卷积神经网络模型相比，优化后的 MobileNetV2 卷积神经网络模型在结肠镜息肉识别率上有所提高。

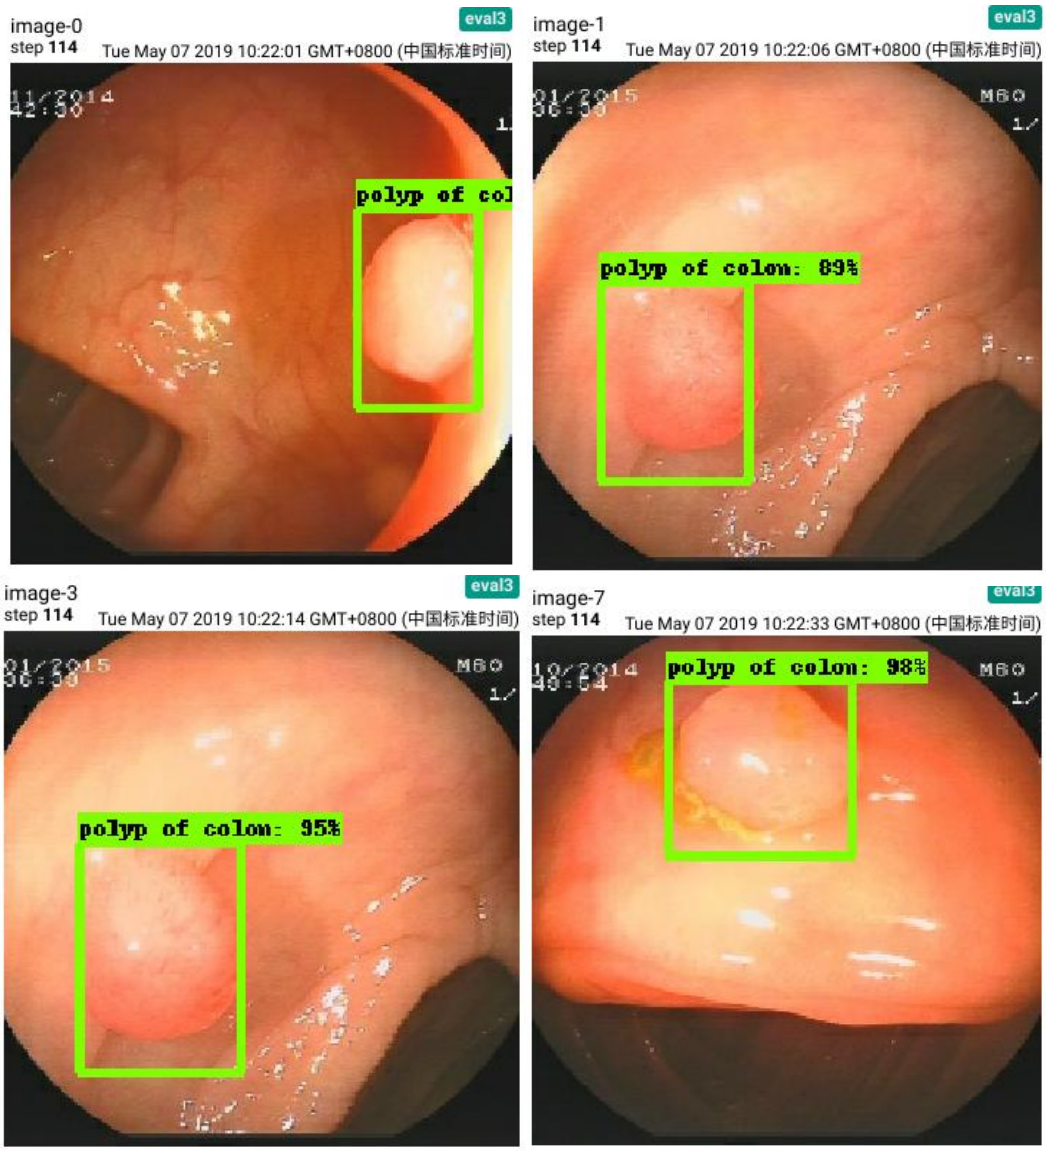

图 18 优化后的训练效果

5.4 本章小结

优化后的结肠息肉模型 MobileNet V2 是 Resnet 和 MobileNet V1 的结合,主要将 Resnet 的 bottleneck 的中间层卷积换成 depthwise separable 卷积以节省空间和计

算量,此外通道数在头尾两个 1×1 卷积中先增加后减少,这点与 Resnet 的 bottleneck 相反。优化后的结肠息肉模型在训练速度上有所下降，但是其他的评价指标如损失函数、交并比等指标与优化前相比表现更为出色。

结 论

基于深度学习的结肠镜息肉检测方法经过多年的发展已较为成熟，并逐步应用于临床医学中。本文在传统的深度学习基础上，采用深度学习领域中具有代表性的 MobileNetV1 算法作为基础，复现出优化后的 MobileNetV2 算法，通过大量结肠镜息肉数据集训练出效果较好的结肠镜息肉检测模型，结肠镜息肉检测模型可识别出结肠镜息肉图片的息肉位置，对息肉位置进行标记。并通过损失函数、交并比、平均精确率均值等具有代表性的评价指标对结肠息肉模型进行了评估，评估结果在现阶段已达到预期目标。

随着深度学习的不断发展进步，深度学习在医学领域的应用也越来越广泛。由于医疗行业对准确性的高要求，未来的基于深度学习的结肠镜息肉检测方法也将在边缘信息的准确提取与分割、提高结肠镜息肉图片像素、加入可变卷积核等方面实现重大突破。

参考文献

[1] R L Siegel, K D Miller, A Jemal. CA: A Cancer Journal for Clinicians[J]. Cancer Statistics, 2016, 66(1): 7-30.

[2] V Prasath. Polyp detection and segmentation from video capsule endoscopy: areview[J].J Imaging, 2017, 3(1): 13-24.

[3] 郭昕．基于深度学习的视觉特征在图像检索中的应用[D]．郑州：河南大学, 2016: 35-42.

[4] Andrew Howard, Menglong Zhu, Bo Chen. MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications[J]. Computer Science, 2017, 4(2): 30-36.

[5] 敖道敢. 无监督特征学习结合神经网络应用于图像识别[D]. 广州: 华南理工大学, 2014: 23-45.

[6] Hinton G E. Deep belief networks[J]. Scholarpedia, 2019, 4(5): 39-47.

[7] 张金．基于深度学习的肺结节识别与检测研究[D]．重庆：西南大学, 2018:

9-17.

[8] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. J Imaging, 2014, 3(1): 13-24.

[9] 孙志军，薛磊. 深度学习研究综述[J]. 计算机应用研究, 2012, 29(8): 28-34.

[10] He K, Ren S. Deep residual learning for image recognition[R]. Las Vegas: IEEE conference on computer vision and pattern recognition(CVPR), 2016: 26-31.

[11] Xie S, Dollar P. Aggregated residual transformations for deep neural networks[R]. Honolulu: IEEE conference on computer vision and pattern recognition(CVPR), 2017: 15-24.

[12] Liu W, Anguelov D, Erhan D. Ssd:Single shot multibox detector[R]. Amsterdam: the european conference on computer vision(ECCV), 2016: 21-37.

[13] 马东梅. 基于深度学习的图像检索研究[D]. 呼和浩特：内蒙古大学，2014: 5-13.

[14] Fu C Y,Ranga A. DSSD:Deconvolutional single shot detector[J]. IEEE Trans Med Imaging, 2017, 36(6): 1231-1249.

[15] Lin T, Goyal P. Focal loss for dense object detection[J]. Compute Medical Biology, 2017, 7: 138-143.

[16] 吕娜. 基于深度层次特征学习的大规模图像分类研究[D]. 成都：电子科技大学，2017: 34-38.

[17] Kang J, Doraiswami R. Real-time image processing system for endoscopic applications[C]. IEEE. Canadian Conference on Electrical and Computer Engineering, Endoscopic Applications, Montreal, Montreal Press, 2013: 1493-1516.

[18] 楚敏南. 基于卷积神经网络的图像分类技术研究[D]. 长沙：湘潭大学，2015:23-39.

[19] Tajbakhsh N, Gurudu SR, Liang J. Automated polyp detection in colonoscopy videos using shape and context information[J]. IEEE Trans Med Imaging, 2016, 35(2): 630-644.

[20] Bernal J, Tajkbaksh N, Sanchez FJ. Comparative validation of polyp detection methods in video colonoscopy: results from the MICCAI 2015 endoscopic vision challenge[J]. IEEE Trans Med Imaging, 2017, 36(6): 1231-1249.

[21] 孙倩，张洁. 结肠镜下计算机辅助息肉检测系统的构建[J]. 中国消化杂志, 2018, 7(38): 473-477.

[22] 杨红丽. 深层神经网络的结构设计方法研究[D]. 北京：北京工业大学，2017:14-17.

[23] Sevo I, Avramovia Balasingham I. Edge density based automatic detection of inflammation in colonoscopy videos[J]. Compute Medical Biology, 2016, 72:

138-150.

[24] Gross S, Thomas S, Behrens A. A comparison of blood vessel features and local binary patterns for colorectal polyp classification[M]. Washington, DC: Society of Photo Optical Press, 2009: 72-89.

[25] Zhu H, Fan Y, Liang Z. Improved curvature estimation for shape analysis in computer-aided detection of colonic polyps[M]. Berlin, Heidelberg: Springer Press, 2010: 9-14.

[26] 孙凯, 史学森, 王吉凌. 双源计算机断层扫描双能量结肠镜检测结肠肿瘤准确性的临床研究[J]. 中华消化杂志, 2015, 35(6): 382-385.

[27] Ravesteijn VF, Wijk C, Vos FM. Computer aided detection of polyps in CT colonography using logistic regression[J]. IEEE Trans Med Imaging, 2010, 29(1): 120-131.

[28] 陈先昌. 基于卷积神经网络的深度学习算法与应用研究[D]. 杭州: 浙江大学, 2017: 9-21.

[29] Hwang S, Tavanapong W. Polyp detection in colonoscopy video using elliptical shape feature[C]. IEEE. IEEE International Conference on Image Processing, 2007 (ICIP 2007), San Antonio, TX Press, 2007: 465-468.

致 谢

衷心感谢导师孙明健老师、高蕾老师对本人的精心指导。在他们悉心的指导、关心和鼓励下，才使得我养成科学严谨的治学态度，也让我学会了如何去解决所遇到的问题，感谢他们让我懂得了科学探索的奥秘在于永远保持一个乐观积极向上的心态以及脚踏实地勤勉的务实作风，他们的言传身教将使我终生受益。

感谢实验室的所有人。在实验室度过了我所有科研时光，当我遇到困难时，他们总是在身旁默默的帮助。感谢深度学习小组的张笑师兄、刘子超师兄、刘志强师弟的合作；还要感谢实验室的李超师兄，刘旭快师兄的帮助。

感谢我的家人。是他们在挫折时，给与我信心与前进的动力；是他们在快乐时分享我的喜悦。

感谢所有关心和帮助过我的人。